




dealHunter

Presented by: Francesco Coppola
Mat. 0512119837





IL PROBLEMA


L'acquirente inesperto del mercato dello smartphone usato non conosce il vero valore del dispositivo che sta acquistando.



AFFARE?



TRUFFA?



LA SOLUZIONE

DealHunter

Il progetto DealHunter affronta il problema della classificazione del prezzo di smartphone usati in categorie predefinite.

Cosa fa?

DealHunter è in grado di:

- Analizzare le specifiche tecniche di un dispositivo
- Predire la fascia di prezzo a cui appartiene il dispositivo nel mercato dell'usato
- Fornire una stima interpretabile per utenti finali



dealHunter

COME LO FA?



TASK

Classificazione multiclasse supervisionata



INPUT

Vettore di feature categoriche e numeriche (specifiche del dispositivo)



CLASSE TARGET

Prezzo normalizzato ingegnerizzato in 4 fasce di prezzo: Budget, Mid-Range, High-End, Premium

OVERVIEW DEL PROCESSO

01

Raccolta
Dati

02

Analisi
Dati e Issue

03

Modelli e
Training

04

Analisi
Prestazioni

05

Considerazioni
Finali

01

RACCOLTA DATI

Fonte: [kaggle](#).

USED_DEVICE_DATA

5K


Downloads

3454

Righe


15

Colonne



Link al dataset

01 RACCOLTA DATI



Link al dataset

Feature	Descrizione	Unità
screen_size	Diagonale schermo	cm
rear_camera_mp	MegaPixel fotocamera post.	MP
front_camera_mp	MegaPixel fotocamera ant.	MP
battery	Capacità batteria	mAh
ram	Memoria RAM	GB
release_year	Anno di uscita	Anno
normalized_new_price	prezzo nuovo normalizzato	Valuta
normalized_used_price	prezzo usato normalizzato	valuta

OVERVIEW DEL PROCESSO

01

Raccolta
Dati

02

Analisi
Dati e Issue

03

Modelli e
Training

04

Analisi
Prestazioni

05

Considerazioni
Finali

01


ISSUE: ZERI FITTIZI

Nel dataset originale sono presenti 0 semanticamente impossibili, probabilmente usati per nascondere dei missing values, nonostante questi siano in bassa quantità, è bene convertirli in NaN per distinguere l'assenza di informazione dal valore numerico zero e permettere l'imputazione.

DISTRIBUZIONE



# front_cam...	#
0	0
0	0
0	0



01

ISSUE: ZERI FITTIZZI

SOLUZIONE



- **Coerenza semantica:** Distinguere l'assenza di informazione dal valore numerico zero.
- **Compatibilità tecnica:** Permettere l'utilizzo degli algoritmi di imputazione standard (che ignorano o gestiscono specificamente i NaN durante il calcolo delle statistiche).

01

ISSUE: ZERI FITTIZZI

SOLUZIONE



MEDIANA LOCALE

La Mediana locale è una soluzione domain-driven, di fatto consideriamo brand e anno come criterio di selezione del gruppo per dare un senso più logico alla nostra imputazione. (Gruppo = Brand + anno)




MEDIANA GLOBALE

soluzione FallBack con la mediana globale della colonna. (in caso di gruppi troppo piccoli)

ISSUE: OUTLIER

Il dataset di partenza conteneva dispositivi con peso $> 300\text{g}$ e schermo $> 20\text{cm}$, questi sono Tablet e non smartphone e rappresentano una piccola parte del dataset, sono stati classificati come outlier.



Sono evidenti circa 270 dispositivi identificati come Tablet, circa l'8% del dataset

02

ISSUE: OUTLIER

SOLUZIONE

- **Eliminazione di tutti i tablet:** I tablet sono in netta minoranza rispetto ai cellulari, inoltre dealHunter ha come task la classificazione di smartphone usati, non tablet.

PERCHÈ?

20


cm

300

grammi

ISSUE: DISTRIBUZIONE SBILANCIATA DEI PREZZI

la colonna target originale (normalized used price) aveva una distribuzione continua e sbilanciata, aveva un picco verso i prezzi bassi e una coda lunga sui prezzi alti.



ISSUE: DISTRIBUZIONE SBILANCIATA DEI PREZZI

Le colonne relative ai prezzi, erano state normalizzate dall'ideatore del dataset secondo una formula a noi sconosciuta.


Feature	Descrizione	Unità
normalized_used_price	prezzo usato normalizzato	Valuta
normalized_new_price	prezzo nuovo normalizzato	Valuta

# normalize...	# normalize...
4.307572449	4.715100245
5.162096647	5.519017936
5.111083765	5.884630724
5.135386588	5.630960854
4.389994804	4.947837479
4.413888608	5.060694494

ISSUE: DISTRIBUZIONE SBILANCIATA DEI PREZZI

SOLUZIONE

- **Eliminazione colonna:**
normalized_new_price fa riferimento al prezzo del dispositivo quando esso è nuovo, non influente nel nostro task e a rischio di confondere il modello.
- **Sostituzione colonna:**
sostituiamo la colonna normalized_used_price con la nuova price_category, calcolata secondo il metodo qcut.



ISSUE: FEATURE CATEGORICHE AD ALTA CARDINALITÀ

Il dataset conteneva oltre 30 produttori diversi (high cardinality), molti dei quali con pochissime osservazioni (es. Alcatel, Celkon). Creare colonne separate permette al modello di assegnare un peso (coefficiente) indipendente e specifico per ogni produttore. Il modello può così apprendere che la presenza del valore 1 nella colonna brand Apple ha un impatto positivo sulla fascia di prezzo, mentre brand Wiko ne ha uno negativo o neutro, senza dover mediare tra loro. I modelli di Machine Learning, come la Logistic Regression, operano su basi puramente algebriche e non possono elaborare dati testuali grezzi.

Non potevamo lasciare le variabili come stringhe perché l'algoritmo richiede input numerici per il calcolo dei coefficienti.

INOLTRE

4 $\neq$ 5000

Ram (gb)

batteria (mAh)

ISSUE: FEATURE CATEGORICHE AD ALTA CARDINALITÀ

SOLUZIONE



TOP MARKET SHARE

Tutti i brand non presenti nella lista dei "Top Market Share" (definiti nella configurazione del progetto) sono stati ricodificati sotto l'etichetta cumulativa "Others".



ONE HOT ENCODING

Successivamente è stato applicato il One-Hot Encoding, generando un numero fisso e gestibile di feature binarie.




STANDARD SCALER

Usiamo uno standard scaler per normalizzare tutte le feature in un intervallo comprensibile.

ISSUE: DATA DRIFT

Il dataset contiene la colonna `release_year` rappresentata in anni, un anno per un modello di ML non è altro che un numero molto grande. inoltre la variabile che influenza il prezzo non è l'anno solare in sé, ma quanto è vecchio il telefono.




05

ISSUE: DATA DRIFT

SOLUZIONE

Il dataset contiene la colonna `release_year` rappresentata in anni, un anno per un modello di ML non è altro che un numero molto grande. inoltre la variabile che influenza il prezzo non è l'anno solare in sé, ma **quanto è vecchio il telefono**.



05

ISSUE: DATA DRIFT

LIMITAZIONE RICONOSCIUTA

Tale soluzione è parziale, specifiche di dispositivi 2021+ potrebbero portare il modello a sottostimarne i prezzi. Il modello potrebbe inoltre trattare dispositivi TOP del 2020 come TOP di gamma attuali

01

RACCOLTA DATI

Fonte: [kaggle](#).

USED_DEVICE_DATA

5K

Downloads

~~3454~~


Righe

3183

~~15~~

Colonne

47



Link al dataset

OVERVIEW DEL PROCESSO

01

Raccolta
Dati

02

Analisi
Dati e Issue

03

Modelli e
Training

04

Analisi
Prestazioni

05

Considerazioni
Finali



03

DATASET SPLIT

STRATIFIED

80%

TRAINING SET




20%

TEST SET



MODELLI CONFRONTATI



▶ **LOGISTIC
REGRESSION** Classificazione Lineare

▶ **RANDOM
FOREST** Ensemble di alberi decisionali

▶ **RANDOM
FOREST TN** Random forest ottimizzato con GridSearchCV

▶ **GRADIENT
BOOSTING** Boosting Sequenziale

OVERVIEW DEL PROCESSO

01

Raccolta
Dati

02

Analisi
Dati e Issue

03

Modelli e
Training

04


Analisi
Prestazioni

05

Considerazioni
Finali

ANALISI ACCURACY


Di seguito è riportata l'analisi delle accuracy dei vari modelli.



04

ANALISI PRESTAZIONI

Di seguito è riportata l'analisi completa delle prestazioni dei vari modelli sulle metriche di Precision, Recall e F1-Score (approssimate per eccesso).



04

CONFUSION MATRIX


Verifichiamo dove si confondono i modelli.

► **LOGISTIC
REGRESSION**

► **RANDOM
FOREST**

► **RANDOM
FOREST TN**

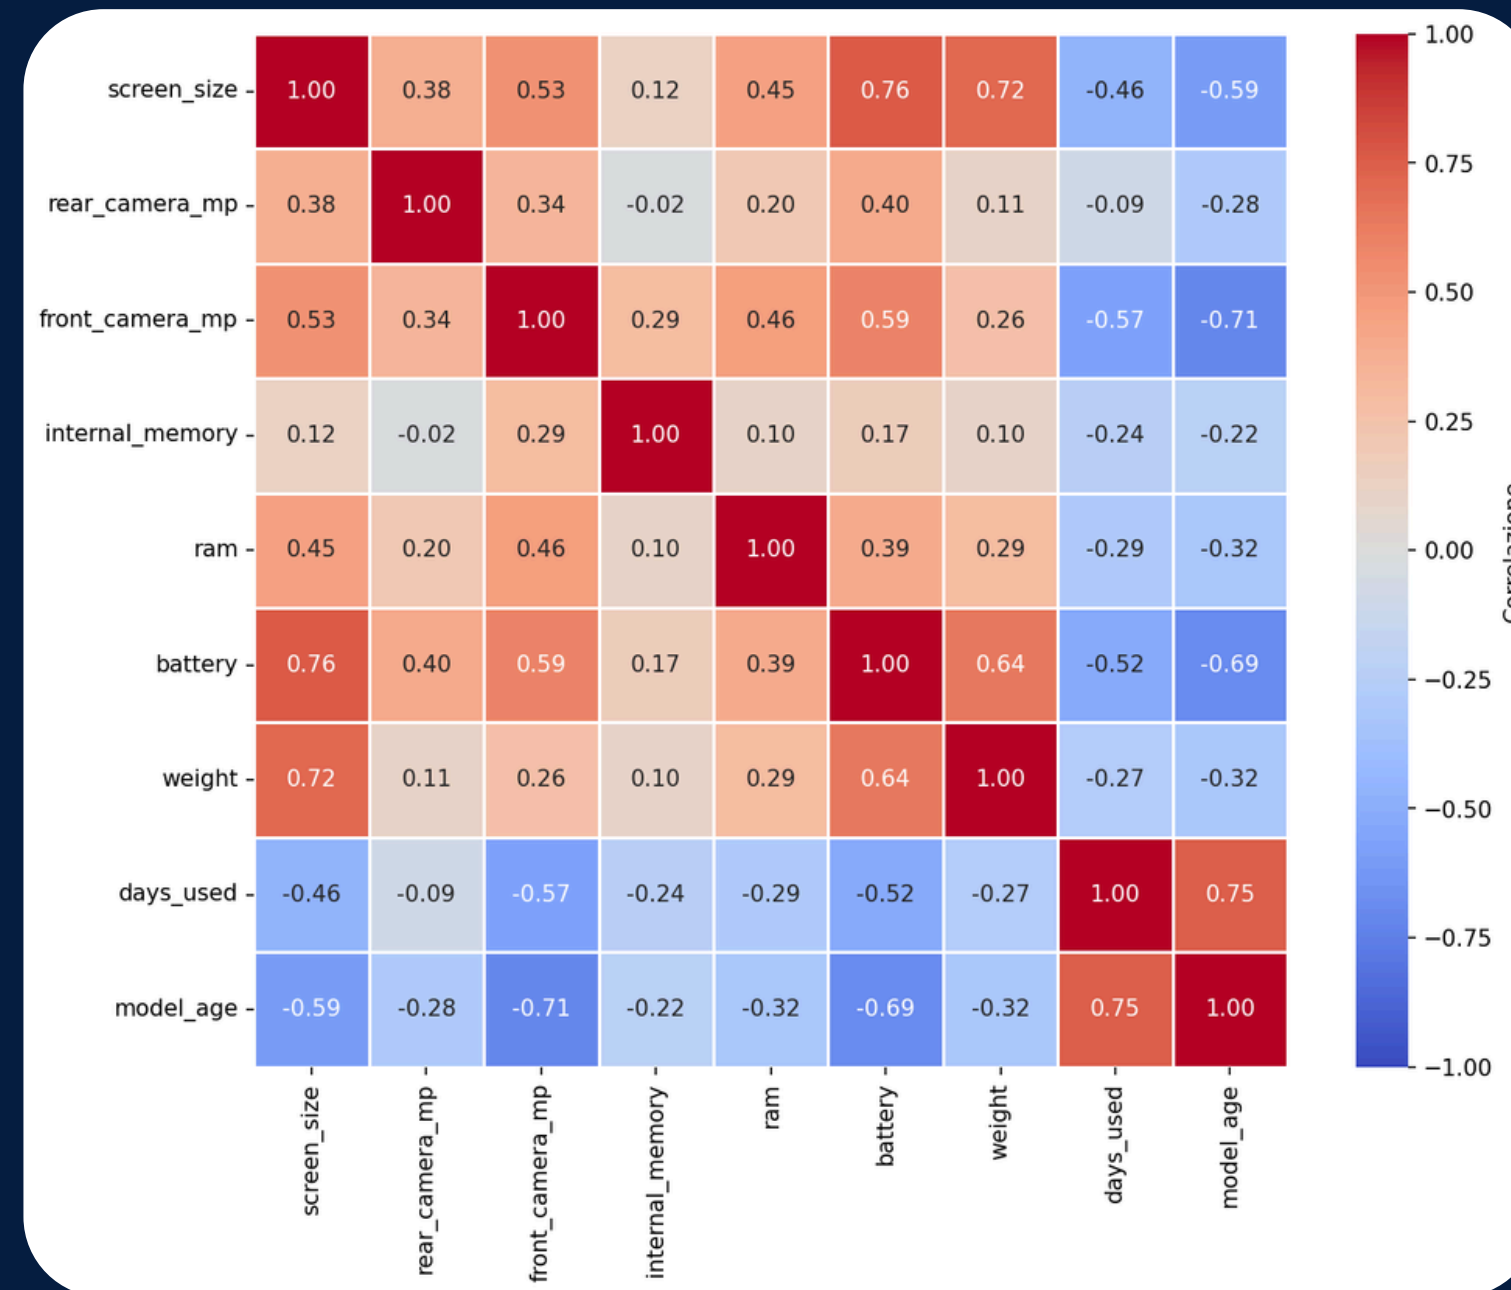
► **GRADIENT
BOOSTING**



04

FEATURE CORRELATION

Questa heatmap ci aiuta a capire la correlazione fra le feature.




▶ **BATTERY**
SCREEN-SIZE

▶ **WEIGHT**
SCREEN-SIZE

▶ **DAYS_USED**
MODEL_AGE

FEATURE IMPORTANCE

Questa heatmap ci aiuta a capire l'importanza (sul prezzo finale) delle varie feature.



▶ CAMERA_MP

▶ MODEL_AGE

04



**LOGISTIC
REGRESSION**
1° Posto

**RANDOM
FOREST
TUNED**
2° Posto

**GRADIENT
BOOSTING**
3° Posto

**RANDOM
FOREST**
4° Posto

OVERVIEW DEL PROCESSO

01

Raccolta
Dati

02

Analisi
Dati e Issue

03

Modelli e
Training

04

Analisi
Prestazioni

05

Considerazioni
Finali

LIMITI DEL MODELLO



- ▶ **ACCURACY**
65%
- ▶ **DATA DRIFT**
- ▶ **EXTERNAL
FEATURE**

**RETRAIN
PERIODICO**



dealHunter

Presented by: Francesco Coppola
Mat. 0512119837

GRAZIE



GitHub